

ODOL Identification: Visual Overload Classification on Heavy Vehicles Using YOLOv11 from CCTV Footage

Serly Eldina
26/589324/PPA/07352
Magister Kecerdasan Artifisial
Fakultas Matematika dan Ilmu
Pengetahuan Alam
Universitas Gadjah Mada
Yogyakarta, Indonesia

Bhima Fairul Rifqi
26/579939/PPA/07301
Magister Kecerdasan Artifisial
Fakultas Matematika dan Ilmu
Pengetahuan Alam
Universitas Gadjah Mada
Yogyakarta, Indonesia

Elsa Aiziyah
25/572243/PPA/07187
Magister Kecerdasan Artifisial
Fakultas Matematika dan Ilmu
Pengetahuan Alam
Universitas Gadjah Mada
Yogyakarta, Indonesia

Abstract—Pengawasan kendaraan yang melanggar batas dimensi dan muatan (*over dimension and over loading*, ODOL) membutuhkan sistem berbasis visi komputer yang mampu mengidentifikasi indikasi pelanggaran dari rekaman *closed-circuit television* (CCTV). Namun, citra kendaraan yang berada jauh dari kamera berukuran kecil, sedangkan arsitektur You Only Look Once versi 11 (YOLOv11) menggunakan *stride convolution* pada proses *downsampling* yang menghilangkan detail spasial beresolusi tinggi secara permanen. Penelitian ini mengusulkan identifikasi indikasi ODOL pada kendaraan berat dengan mengklasifikasikan citra kendaraan menjadi normal atau indikasi ODOL menggunakan YOLOv11 klasifikasi yang *stride convolution*-nya diganti dengan *space-to-depth convolution* (SPD-Conv). Data berasal dari *Real-Time Traffic Dataset-500 Videos*, yaitu video lalu lintas perkotaan dari kamera tetap dengan anotasi *bounding box*, yang dipotong menjadi citra kendaraan berat. Karena dataset tidak menyediakan label ODOL, pelabelan dilakukan secara manual berdasarkan kriteria visual oleh dua anotator, dan kesepakatannya diukur dengan koefisien Cohen's κ . Kinerja model akan dievaluasi menggunakan *accuracy*, *precision*, *recall*, dan *F1-score*. Penelitian ini diharapkan menghasilkan karakterisasi kinerja identifikasi indikasi ODOL secara visual sebagai dasar pendukung pengawasan ODOL.

Keywords—CCTV, heavy vehicles, image classification, ODOL identification, SPD-Conv, YOLOv11.

I. LATAR BELAKANG

Perkembangan teknologi kecerdasan buatan (*artificial intelligence*) dalam bidang transportasi telah menjadi salah satu pendekatan penting dalam mendukung peningkatan keselamatan dan efisiensi lalu lintas. Namun, penerapan teknologi tersebut pada lingkungan lalu lintas yang kompleks masih menghadapi berbagai tantangan, terutama akibat keberagaman jenis dan ukuran kendaraan, karakteristik latar belakang objek yang kompleks, serta kondisi lingkungan yang dapat memengaruhi kemampuan sistem dalam melakukan identifikasi secara akurat [1]. Salah satu persoalan yang banyak dikaji pada kendaraan berat adalah *over dimension and over loading* (ODOL), yaitu kendaraan yang dimensi atau muatannya melebihi ketentuan [1],[2]. Penelitian terdahulu telah memanfaatkan visi komputer untuk mendukung penanganan ODOL, antara lain melalui algoritma YOLO [3], [4], [16], [17] dan pengenalan model truk untuk deteksi kelebihan muatan otomatis [3]. Meskipun demikian, pada kendaraan yang berada jauh dari kamera CCTV, citra kendaraan hanya menempati sedikit piksel

sehingga detail visual yang menjadi petunjuk dimensi dan muatan mudah hilang [5].

Kebutuhan terhadap sistem identifikasi kendaraan yang lebih andal menjadi semakin relevan dalam konteks pengawasan kendaraan berat. Undang-Undang Nomor 22 Tahun 2009 tentang Lalu Lintas dan Angkutan Jalan (UU LLAJ) Paragraf 3 Pasal 162 mengatur ketentuan terkait operasional kendaraan berat, termasuk pembatasan waktu operasional kendaraan sejenis pada wilayah tertentu. Ketentuan tersebut berkaitan dengan karakteristik kendaraan berat yang memiliki keterbatasan area pandang (*blind spot*), sehingga berpotensi meningkatkan risiko interaksi yang tidak terdeteksi antara kendaraan berat, pengguna jalan, dan lingkungan di sekitarnya. Pusat Informasi Kriminal Nasional (Pusiknas) melalui situs KataData mencatat sebanyak 39.461 pelanggaran lalu lintas yang dilakukan oleh truk besar dan kontainer. Kondisi tersebut menunjukkan bahwa pengawasan terhadap aktivitas kendaraan berat masih menghadapi tantangan, salah satunya berkaitan dengan keterbatasan sumber daya dalam melakukan pemantauan secara berkelanjutan [6]. Oleh karena itu, diperlukan pendekatan berbasis visi komputer yang mampu melakukan identifikasi kendaraan ODOL secara otomatis dan akurat sebagai bagian dari upaya meningkatkan efektivitas sistem pengawasan lalu lintas [7], [8].

Salah satu pendekatan yang banyak digunakan dalam pengenalan citra adalah keluarga model *You Only Look Once* (YOLO), yang terus mengalami perkembangan dengan orientasi pada peningkatan efisiensi dan kemampuan pengenalan. YOLOv11 [9], salah satu pengembangan terbaru, tidak hanya menyediakan varian deteksi objek tetapi juga varian klasifikasi citra. Namun, *backbone* YOLOv11 menggunakan *stride convolution* tradisional untuk proses *downsampling*, yang menyebabkan hilangnya secara permanen detail spasial beresolusi tinggi. Kondisi tersebut merugikan pada citra beresolusi rendah dan objek berukuran kecil [10], seperti citra kendaraan berat yang berjarak jauh dari kamera CCTV, karena detail geometri dan tekstur yang menjadi petunjuk ODOL, misalnya muatan yang menjulang atau menjorok, dapat hilang sebelum citra diklasifikasikan.

Berdasarkan keterbatasan tersebut, penelitian ini mengusulkan identifikasi indikasi ODOL pada kendaraan berat melalui klasifikasi citra kendaraan menjadi normal atau indikasi ODOL menggunakan YOLOv11 yang *stride convolution*-nya diganti dengan *space-to-depth convolution* (SPD-Conv) [10] agar informasi spasial tetap terjaga selama *downsampling*. SPD-Conv dipilih karena dapat dipasang

langsung pada arsitektur tanpa mengubah bagian model lain. Karena dataset yang digunakan tidak menyediakan label ODOL, label dibuat secara manual berdasarkan kriteria visual. Perlu ditegaskan bahwa yang diidentifikasi adalah indikasi visual berupa dimensi dan muatan yang tampak, bukan berat muatan sebenarnya. Dengan demikian, penelitian ini mengevaluasi kemampuan YOLOv11 yang dimodifikasi dalam mengidentifikasi indikasi ODOL pada citra kendaraan berat dari rekaman CCTV lalu lintas.

II. RUMUSAN MASALAH

Berdasarkan permasalahan yang telah diuraikan, penelitian ini berfokus pada identifikasi indikasi ODOL pada kendaraan berat dari rekaman CCTV, khususnya pada citra kendaraan berukuran kecil dan berjarak jauh yang detail spasialnya mudah hilang akibat proses *downsampling* dengan *stride convolution*. Permasalahan tersebut dirumuskan ke dalam pertanyaan penelitian mengenai bagaimana kinerja YOLOv11 klasifikasi yang *stride convolution*-nya diganti dengan SPD-Conv dalam mengidentifikasi kendaraan berat normal dan kendaraan dengan indikasi ODOL.

III. TUJUAN PENELITIAN

Penelitian ini bertujuan membangun model identifikasi indikasi ODOL pada kendaraan berat berbasis YOLOv11 klasifikasi yang dimodifikasi dengan SPD-Conv, serta mengevaluasi kinerjanya pada citra kendaraan yang diperoleh dari *Real-Time Traffic Dataset-500 Videos* menggunakan *accuracy*, *precision*, *recall*, dan *F1-score*. Evaluasi juga dilakukan pada kelompok citra berukuran kecil dan besar untuk mengetahui kemampuan model mempertahankan informasi kendaraan yang berjarak jauh. Penelitian ini tidak membandingkan model dengan metode lain, sehingga hasilnya digunakan untuk mengkarakterisasi kinerja model yang diusulkan.

IV. DATASET

Penelitian ini menggunakan *Real-Time Traffic Dataset-500 Videos* yang diterbitkan oleh Unidata melalui Kaggle [18]. Dataset terdiri atas 500 video lalu lintas perkotaan yang direkam oleh kamera tetap pada persimpangan dan penyeberangan jalan, sehingga merepresentasikan kondisi pengawasan CCTV dengan sudut pandang konstan. Video berformat MP4 dengan resolusi minimum 1920×1080 piksel. Contoh *frame* ditunjukkan pada Gambar 4.1, dan ringkasan spesifikasi dataset disajikan pada Tabel I.

Setiap video dilengkapi anotasi *bounding box* berformat JSON untuk objek kendaraan dan pejalan kaki (kelas *cars* dan *pedestrians*). Menurut deskripsi penyedia, anotasi juga memuat metadata berupa waktu pengambilan, kondisi cuaca (hujan, salju, dan kabut), jumlah kendaraan dan pejalan kaki, serta status lampu lalu lintas, dan kendaraan dikelompokkan sebagai *light vehicles* dan *heavy vehicles*. Ketersediaan atribut tersebut pada salinan Kaggle diperiksa terlebih dahulu sebelum digunakan. Dataset ini dirancang untuk deteksi objek; pada penelitian ini kotak anotasi kendaraan dipotong menjadi citra untuk keperluan identifikasi.



Gambar 4.1 Sampel dataset


TABEL I. RINGKASAN SPESIFIKASI DATASET

Atribut	Keterangan
Sumber	Unidata, melalui Kaggle [18]
Jumlah video	500 video lalu lintas perkotaan
Sudut pandang	Kamera tetap; persimpangan dan penyeberangan jalan
Format video	MP4, resolusi minimum 1920×1080 piksel
Anotasi	<i>Bounding box</i> , format JSON
Objek	Kendaraan (<i>cars</i>) dan pejalan kaki (<i>pedestrians</i>)
Kategori kendaraan	<i>Light vehicles</i> dan <i>heavy vehicles</i>
Label ODOL	Tidak tersedia

Terdapat empat keterbatasan dataset yang diperhitungkan dalam rancangan penelitian. Pertama, dataset tidak menyediakan label ODOL, sehingga label identifikasi dibuat secara manual berdasarkan kriteria visual (Subbagian V-B). Kedua, kategori *heavy vehicles* pada dataset belum tentu setara dengan kendaraan berat pada konteks ODOL, yaitu truk, bus, dan kontainer, sehingga kendaraan berat dipilih melalui verifikasi visual (Subbagian V-A). Ketiga, karena kamera bersifat tetap, banyak video dapat berbagi latar yang sama sehingga pembagian data harus mencegah kebocoran latar (Subbagian V-A). Keempat, kendaraan dengan indikasi ODOL diperkirakan jarang muncul pada lalu lintas perkotaan sehingga jumlah kedua kelas berpotensi tidak seimbang.

V. METODE PENELITIAN

Penelitian ini menggunakan pendekatan berbasis *deep learning* untuk mengidentifikasi indikasi ODOL pada kendaraan berat melalui klasifikasi citra kendaraan yang dipotong dari rekaman CCTV lalu lintas. Sebagaimana ditunjukkan pada Gambar 5.1, alur penelitian terdiri atas enam tahap, yaitu pengumpulan data, persiapan data, pelabelan ODOL, *preprocessing* dan augmentasi, pelatihan model, serta evaluasi dan analisis hasil identifikasi. Tahap-tahap tersebut diuraikan pada Subbagian A hingga I berikut.



Gambar 5.1 Rancangan alur penelitian

A. Pengumpulan dan Persiapan Data

Data penelitian adalah *Real-Time Traffic Dataset-500 Videos* [18] yang dijelaskan pada Bagian IV. Mengingat keterbatasan waktu dan sumber daya, digunakan subset video yang dipilih karena memuat kendaraan berat. Setiap video diekstraksi menjadi *frame* dengan interval waktu tetap (misalnya satu *frame* per detik). Interval ditetapkan berdasarkan waktu karena laju bingkai (*frame rate*) video tidak dinyatakan pada deskripsi dataset, dan tujuannya mengurangi redundansi antar-*frame* berurutan.

Dataset semula ditujukan untuk deteksi objek, sehingga pada penelitian ini kotak anotasi dipotong (*crop*) dari *frame* menjadi citra kendaraan. Dengan cara ini tidak diperlukan model deteksi, karena lokasi kendaraan sudah tersedia pada anotasi. Untuk memilih kendaraan berat secara efisien, digunakan pra-label semiotomatis. Detektor YOLO yang telah dilatih pada COCO, tanpa dilatih ulang, dijalankan pada *frame*, dan kotak berkelas *truck* atau *bus* dicocokkan dengan kotak *cars* pada anotasi berdasarkan IoU (misalnya ≥ 0.5). Kotak yang cocok menjadi kandidat kendaraan berat. Seluruh kandidat kemudian diverifikasi secara visual, dan atribut *heavy vehicles* pada metadata dataset, bila tersedia, digunakan sebagai pembanding. Citra yang sisi terpendeknya kurang dari 32 piksel, terpotong di tepi *frame*, atau terhalang berat dibuang karena tidak memungkinkan penilaian visual.

Pembagian data dilakukan dengan rasio 70:15:15 untuk data latih, validasi, dan uji pada tingkat video, bukan tingkat citra, karena kendaraan yang sama muncul pada banyak *frame* berurutan sehingga pembagian per citra menyebabkan kebocoran data (*data leakage*). Karena kamera bersifat tetap dan satu lokasi dapat direkam pada beberapa video, pembagian dilakukan per lokasi apabila lokasi kamera dapat diidentifikasi dari metadata atau kemiripan latar. Pembagian dibuat berstrata agar kedua kelas hadir pada ketiga subset. Jumlah citra per kelas pada tiap subset dilaporkan setelah tahap pelabelan.

B. Pelabelan Indikasi ODOL

Dataset tidak menyediakan label ODOL, sehingga label dibuat secara manual dengan dua kelas, yaitu normal dan indikasi ODOL. Berat muatan aktual tidak dapat dinilai dari citra, sehingga pelabelan hanya didasarkan pada petunjuk visual dimensi dan muatan yang tampak (Tabel II). Kriteria ini dituangkan dalam panduan pelabelan tertulis agar penilaian konsisten.

TABEL II. KRITERIA PELABELAN INDIKASI ODOL

Kelas	Petunjuk visual
Normal	Muatan tidak melebihi tinggi bak atau kabin, tidak menjorok ke samping atau belakang, dan bentuk bak tampak sesuai kendaraan sejenis
Indikasi ODOL	Muatan menjulang melebihi tinggi bak atau kabin, menjorok ke samping atau belakang, atau bak tampak ditinggikan atau dimodifikasi
Dikecualikan	Kendaraan terlalu kecil, terpotong, terhalang berat, atau tidak dapat dinilai

Pelabelan dilakukan secara independen oleh dua anggota tim. Tingkat kesepakatan diukur dengan koefisien Cohen's κ , dan citra yang penilaiannya berbeda diselesaikan melalui diskusi hingga tercapai label akhir. Karena kendaraan ODOL diperkirakan jarang muncul pada lalu lintas perkotaan, target minimal adalah sekitar 100 citra per kelas; video tambahan dipilih bila target belum tercapai. Ketidakseimbangan kelas yang tersisa ditangani dengan bobot kelas pada fungsi *loss* dan pengambilan sampel ulang (*oversampling*) pada data latih.

C. Preprocessing dan Augmentasi Data


Setiap citra diubah ukurannya menjadi 224×224 piksel dengan mempertahankan rasio aspek melalui penambahan *padding*, lalu nilai piksel dinormalisasi mengikuti statistik ImageNet karena bobot awal berasal dari ImageNet. Augmentasi hanya diterapkan pada data latih, meliputi *horizontal flip*, perubahan *hue-saturation-value* (HSV), serta penskalaan dan translasi acak dalam rentang kecil. *Flip* vertikal tidak digunakan karena orientasi kendaraan pada CCTV selalu tegak, dan augmentasi tidak boleh memotong bagian muatan sehingga petunjuk ODOL hilang. Data validasi dan uji tidak diaugmentasi.

D. Arsitektur Dasar YOLOv11 Klasifikasi

YOLOv11 menyediakan varian klasifikasi citra (YOLOv11-cls) yang menggunakan *backbone* YOLOv11 [9]. *Backbone* mengekstraksi fitur melalui konvolusi ber-*stride* 2 dan blok C3k2, serta C2PSA pada tahap akhir. *Head* klasifikasi terdiri atas *global average pooling* dan lapisan linear yang menghasilkan probabilitas dua kelas. Varian YOLOv11n-cls dipilih karena ringan dilatih dengan sumber daya komputasi terbatas.

E. Modifikasi Arsitektur: SPD-Conv

Konvolusi ber-*stride* 2 pada proses *downsampling* menghilangkan detail spasial beresolusi tinggi secara permanen, sehingga merugikan pada citra beresolusi rendah [10], seperti citra kendaraan berjarak jauh dari kamera CCTV. Oleh karena itu, konvolusi ber-*stride* 2 pada *backbone* diganti dengan *space-to-depth convolution* (SPD-Conv) [10], seperti terlihat pada Gambar 5.2, sedangkan bagian model lain dan fungsi *loss* tidak diubah. SPD-Conv dipilih karena dapat dipasang langsung pada berkas konfigurasi tanpa mengubah bagian model lain.



Gambar 5.2 Arsitektur YOLOv11 yang diusulkan

Untuk fitur $X \in \mathbb{R}^{C \times H \times W}$, transformasi *space-to-depth* dengan faktor 2 menghasilkan empat sub-fitur

$$f_{x,y} = X[x:H:2, y:W:2], \quad x, y \in \{0,1\} \quad (1)$$

yang digabungkan sepanjang dimensi kanal, lalu diproses dengan konvolusi ber-*stride* 1:

$$X_s = \text{Concat}(f_{0,0}, f_{1,0}, f_{0,1}, f_{1,1}) \quad (2)$$

$$Y = \text{Conv}_{3 \times 3}(X_s) \quad (3)$$

sehingga $X_s \in \mathbb{R}^{4C \times H/2 \times W/2}$. Dengan cara ini resolusi spasial direduksi tanpa membuang piksel, karena informasi dipindahkan ke dimensi kanal dan bukan dihilangkan. Modul atensi seperti EMA [15] tidak digunakan pada penelitian ini dan dicatat sebagai pengembangan lanjutan.

F. Strategi Pelatihan

Model dilatih dengan *transfer learning*: bobot YOLOv11n-cls yang telah dilatih pada ImageNet digunakan untuk lapisan yang tidak dimodifikasi, sedangkan lapisan SPD-Conv diinisialisasi secara acak. Fungsi *loss* adalah *cross-entropy* berbobot kelas:

$$L = -\sum_{c=1}^2 w_c y_c \log p_c \quad (4)$$

dengan y_c label sebenarnya (*one-hot*), p_c probabilitas prediksi kelas c , dan w_c bobot kelas yang berbanding terbalik dengan frekuensinya pada data latih. Hiperparameter pelatihan dirangkum pada Tabel III. Model dilatih satu kali dengan *seed* tetap agar hasilnya dapat direproduksi, dan model terbaik dipilih berdasarkan *F1-score* kelas indikasi ODOL pada data validasi.

TABEL III. HIPERPARAMETER PELATIHAN

Parameter	Nilai
Model dasar / bobot awal	YOLOv11n-cls / ImageNet
Ukuran masukan	224×224
Epoch	50 (<i>early stopping, patience</i> 15)
Ukuran batch	32
Optimizer	AdamW
Laju belajar awal	0.001 (peluruhan kosinus)
Weight decay	5×10^{-4}
Warm-up	3 epoch

Parameter	Nilai
Bobot kelas	Berbanding terbalik frekuensi
Seed	0

G. Skenario Evaluasi

Model hasil pelatihan dievaluasi sekali pada data uji yang tidak melibatkan dalam pelatihan maupun pemilihan model. Penelitian ini bertujuan mengkarakterisasi kinerja model yang diusulkan dan tidak membandingkannya dengan model lain. Hasil dilaporkan dalam bentuk matriks konfusi dan metrik per kelas, serta dipisahkan menurut ukuran citra (sisi terpendek kurang dari 64 piksel sebagai kelompok kecil dan selebihnya sebagai kelompok besar) untuk mengetahui kemampuan model pada kendaraan yang berjarak jauh. Apabila metadata tersedia, hasil juga dipisahkan menurut kondisi waktu pengambilan dan cuaca.

H. Metrik Evaluasi

Identifikasi bersifat biner dengan indikasi ODOL sebagai kelas positif. *True positive* (TP) adalah citra ODOL yang teridentifikasi benar, *false positive* (FP) adalah citra normal yang salah teridentifikasi sebagai ODOL, *false negative* (FN) adalah citra ODOL yang terlewat, dan *true negative* (TN) adalah citra normal yang teridentifikasi benar. Berdasarkan keempat nilai tersebut dihitung *accuracy*, *precision*, *recall*, dan *F1-score*:

$$\text{Accuracy} = \frac{TP+TN}{TP+TN+FP+FN} \quad (5)$$

$$P = \frac{TP}{TP+FP} \quad (6)$$

$$R = \frac{TP}{TP+FN} \quad (7)$$

$$F_1 = \frac{2PR}{P+R} \quad (8)$$

Karena data tidak seimbang, *accuracy* saja dapat menyesatkan, sehingga *precision*, *recall*, dan *F1-score* dilaporkan untuk kedua kelas beserta rata-ratanya (*macro-F1*):

$$\text{Macro-F1} = \frac{1}{2}(F_{1,\text{ODOL}} + F_{1,\text{normal}}) \quad (9)$$

Recall kelas indikasi ODOL mendapat perhatian khusus karena kendaraan ODOL yang terlewat lebih merugikan pengawasan dibandingkan peringatan palsu yang masih dapat diperiksa petugas. Efisiensi model diukur melalui jumlah parameter, GFLOPs, dan waktu inferensi per citra.

I. Analisis Hasil dan Batasan

Analisis kuantitatif meninjau matriks konfusi dan seluruh metrik pada Subbagian H untuk tiap kelas dan kelompok ukuran citra. Analisis kualitatif meninjau contoh citra yang teridentifikasi benar dan salah, khususnya kendaraan kecil, terhalang, atau bermuatan tidak jelas, dan bila waktu memungkinkan, peta aktivasi (misalnya Grad-CAM) untuk memeriksa apakah model memperhatikan bagian muatan. Kesalahan dikategorikan berdasarkan ukuran citra, tingkat keterhalangan, dan jenis petunjuk ODOL.

Penelitian ini memiliki beberapa batasan. Pertama, model tidak dibandingkan dengan YOLOv11-cls tanpa modifikasi maupun model lain, sehingga hasil tidak digunakan untuk menyatakan peningkatan relatif. Kedua, yang diidentifikasi adalah indikasi visual dimensi dan muatan, bukan berat muatan aktual, sehingga hasil bukan penentuan pelanggaran.

Ketiga, label dibuat secara manual dan bersifat subjektif, dan kualitasnya dinilai melalui Cohen's κ . Keempat, penelitian menggunakan subset dataset dengan jumlah citra ODOL yang terbatas serta satu kali pelatihan. Kelima, citra dipotong dari kotak anotasi, sehingga hasil belum mencerminkan sistem lengkap yang memerlukan detektor kendaraan; kinerja pada sistem lengkap dapat lebih rendah.

REFERENCES

- [1] A. Widyanti, J. M. Gananda, T. Yudhistira, W. Weningtyas, L. P. Bowo, and S. Nugoroho, "Over-dimension and over-load (ODOL) truck in highways: Prevalence and modeling intention to operate ODOL truck, lesson learned from Indonesia," *Transportation Research Interdisciplinary Perspectives*, vol. 29, p. 101320, 2025, doi: 10.1016/j.trip.2024.101320.
- [2] J. Suttanuruk, S. Jomnonkwao, V. Ratanavaraha, and S. Kanjanawattana, "Convolutional neural network for overcrowded public transportation pickup truck detection," *Computers, Materials & Continua*, vol. 74, no. 3, pp. 5573–5588, 2023, doi: 10.32604/cmc.2023.033900.
- [3] J. Sun, J. Su, Z. Yan, Z. Gao, Y. Sun, and L. Liu, "Truck model recognition for an automatic overload detection system based on the improved MMAL-Net," *Frontiers in Neuroscience*, vol. 17, p. 1243847, 2023, doi: 10.3389/fnins.2023.1243847.
- [4] Z. Zhang, Z. Zhang, G. Li, and C. Xia, "ZZ-YOLOv11: A lightweight vehicle detection model based on improved YOLOv11," *Sensors*, vol. 25, no. 11, p. 3399, 2025, doi: 10.3390/s25113399.
- [5] Y. Tian and Y. Dong, "Transformer-enhanced lightweight detector: YOLOv11-TSO for small objects in traffic surveillance," *Alexandria Engineering Journal*, vol. 149, pp. 40–59, 2026, doi: 10.1016/j.aej.2026.05.033.
- [6] S. Sutikno, A. Sugiharto, R. Kusumaningrum, and H. A. Wibawa, "Improved car detection performance on highways based on YOLOv8," *Bulletin of Electrical Engineering and Informatics*, vol. 13, no. 5, pp. 3526–3533, 2024, doi: 10.11591/eei.v13i5.8031.
- [7] A. Saadeldin, M. M. Rashid, A. A. Shafie, and T. F. Hasan, "Real-time vehicle counting using custom YOLOv8n and DeepSORT for resource-limited edge devices," *TELKOMNIKA*, vol. 22, no. 1, pp. 104–112, 2024, doi: 10.12928/telkomnika.v22i1.25096.
- [8] V. Kandasamy, A. Taurshia, T. M. Thiyagu, C. J. RusselRaj, and J. Archpaul, "YOLOv8-TMS: Spatiotemporal attention networks for real-time occlusion-resilient urban traffic monitoring," *IAES International Journal of Artificial Intelligence*, vol. 15, no. 2, pp. 1709–1718, 2026, doi: 10.11591/ijai.v15.i2.pp1709-1718.
- [9] R. Khanam and M. Hussain, "YOLOv11: An overview of the key architectural enhancements," arXiv:2410.17725, 2024. [Online]. Available: <https://arxiv.org/abs/2410.17725>
- [10] R. Sunkara and T. Luo, "No more strided convolutions or pooling: A new CNN building block for low-resolution images and small objects," in *Machine Learning and Knowledge Discovery in Databases (ECML PKDD 2022)*, LNCS 13715, Springer, 2023, pp. 443–459, doi: 10.1007/978-3-031-26409-2_27.
- [11] B. Khalili and A. W. Smyth, "SOD-YOLOv8—Enhancing YOLOv8 for small object detection in aerial imagery and traffic scenes," *Sensors*, vol. 24, no. 19, p. 6209, 2024, doi: 10.3390/s24196209.
- [12] G. Yang, J. Lei, Z. Zhu, S. Cheng, Z. Feng, and R. Liang, "AFPN: Asymptotic feature pyramid network for object detection," in *Proc. 2023 IEEE Int. Conf. Systems, Man, and Cybernetics (SMC)*, 2023, pp. 1–6, doi: 10.1109/SMC53992.2023.10394415.
- [13] M. Zhong, Y. Zhou, Y. Wang *et al.*, "BiFP-ATFL-YOLO11: An enhanced YOLO11-based object detector with BiFPN and adaptive threshold focal loss for street view perception," *Applied Intelligence*, vol. 56, p. 256, 2026, doi: 10.1007/s10489-026-07268-0.
- [14] J. Fan, W. Chen, L. Du, W. Zhong, W. Yang, and M. Ren, "Improved YOLOv11 for multi-class vehicle detection from the perspective of unmanned aerial vehicles," in *Proc. ICAUS 2025*, LNEE 1580, Springer, 2026, doi: 10.1007/978-981-95-7660-9_35.
- [15] D. Ouyang, S. He, G. Zhang, M. Luo, H. Guo, J. Zhan, and Z. Huang, "Efficient multi-scale attention module with cross-spatial learning," in *Proc. ICASSP 2023*, IEEE, 2023, pp. 1–5, doi: 10.1109/ICASSP49357.2023.10096516.
- [16] M. R. Tsani, H. E. Saputra, M. I. Rafiqi, and H. Y. Ramadhan, "Artificial intelligence-based detection of overdimensioned and overloaded (ODOL) vehicles using the YOLO algorithm for sustainable transportation infrastructure (SDG 9)," *Journal of Current Studies in SDGs*, vol. 3, no. 2, 2027, doi: 10.63230/jocsis.3.2.193.
- [17] A. Pradana, R. R. O. Sasue, and S. A. Ermanto, "Design and development of an over-dimension estimation device using the YOLO algorithm and OpenCV," *Jurnal Teknologi Transportasi dan Logistik*, vol. 5, no. 2, pp. 189–202, 2024, doi: 10.52920/jttl.v5i2.357.
- [18] Unidata, "Real-time traffic dataset – 500 videos," *Kaggle*. Accessed: Sep. 30, 2026. [Online]. Available: <https://www.kaggle.com/datasets/unidpro/real-time-traffic-video-dataset>